Welcome

Data Mining Economía y Finanzas - 2026 - Comisión 1

Los Joacos + Ale Bolaños

Sobre Mí, Sobre Ustedes

- ¿Quiénes somos?
- Check in: de que se trata.
- Sobre sus cursadas del cuatrimestre anterior

Sobre esta Materia > Objetivo

Resolver un problema de dimensiones reales del mercado argentino utilizando las herramientas tecnológicas para manejar grandes volúmenes de datos y ser capaz de generar una predicción competitiva en el mercado profesional laboral argentino.

Sobre esta Materia > ¿Qué vamos a ver?

- Metodologías

  Aprender a pensar

- Algoritmos y técnicas de última generación de modelado predictivo sobre datos estructurados.

  Usar las mejores herramientas

- MLOps

  Saltar de las notebook a los procesos

- Big Data en la nube

  Vamos a jugar a lo grande

- Uso de Agentes para asistir a la creación modelos

  Vamos a *alucinar* a lo grande

Sobre esta Materia > ¿Cómo lo vamos a ver?

Sincrónicamente en Clases presenciales (Lunes + Plenarias)

- Escucharnos
- Actividades - (traigan Notebook cada 2 o 3 alumnos)
- Presentaciones de compañeros

Asincrónicamente a través de Zulip

- Consultas
- Desarrollo de experimentos
- Memes

Sobre esta Materia > El libro de la Asignatura

People : what's your religion ?

Me :



Sobre esta Materia > Uso de Zulip



#general > Python
Ehh fiera!! mira lo que cranee…

#Estrategias > Cálculo de la ...
Se me ocurrió la idea …

- Sean prolijos al utilizarlo.
- Si tiene una consulta o algo para compartir, escriba siempre en el stream correcto (#), con un tópico autoexplicativo que sirva para saber de qué se va tratar.
- Si va a responder verifique que está respondiendo al hilo.

https://uba26.zulip.rebelare.com

Sobre esta Materia > 23 EXPERIMENTOS



Son experimentos de construcción colaborativa.

No todos van a hacen todos.

El fin es ayudarles a experimentar de forma correcta y que los resultados ayuden también a sus compañeros a entregar mejores modelos.

Sobre esta Materia > Qué vamos a usar?

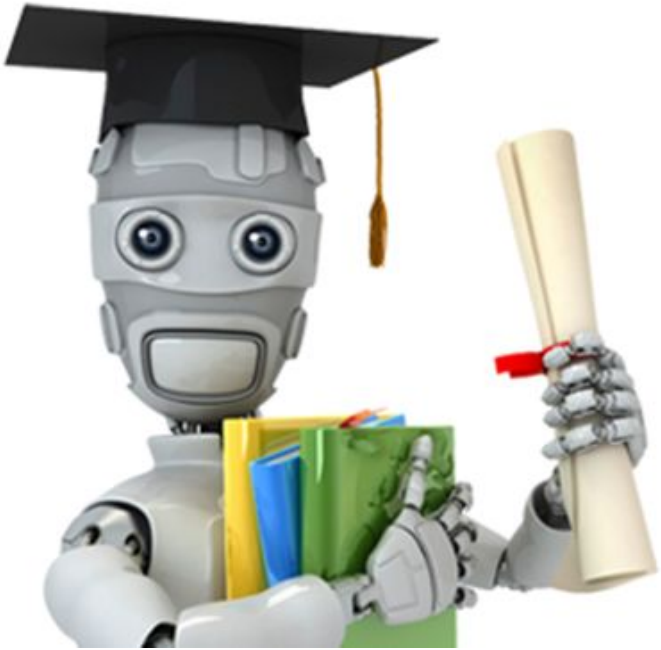




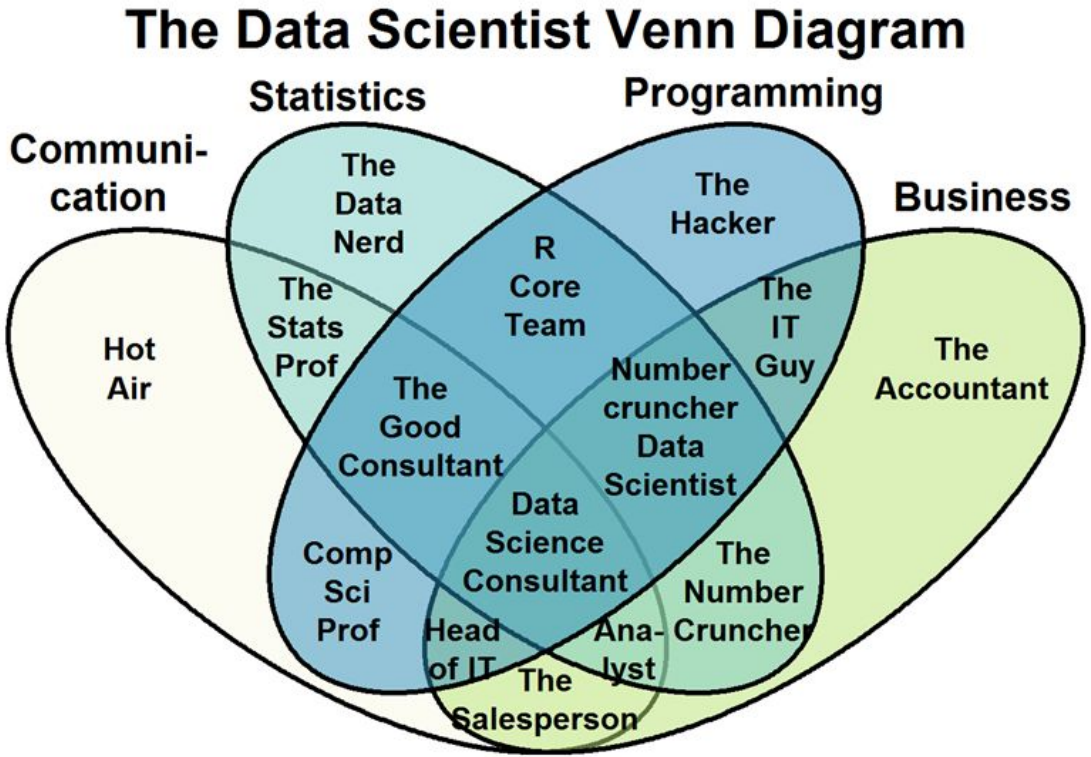


Pero NO hay limitaciones, usted puede usar lo que quiera

Storytelling



Storytelling > Usted, un unicornio



Storytelling



Storytelling



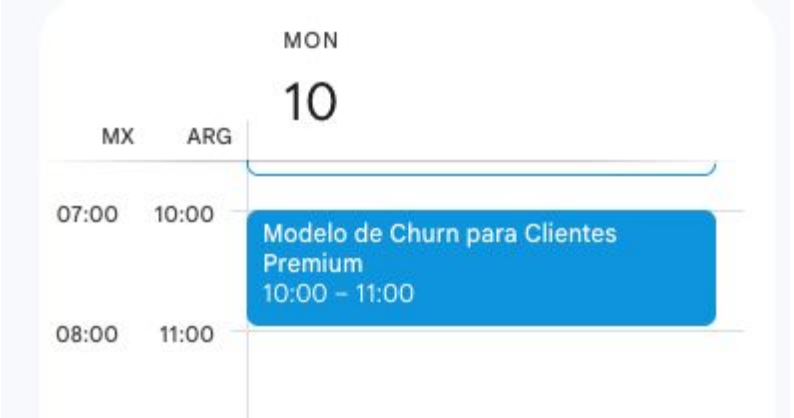
Michelina Porto
Gerente de BI
(Cassie Kozyrkov -former Chief Decision Scientist - Google)



Miranda Wintour
Directora Comercial
(Mary Barra - CEO General Motors)

Storytelling

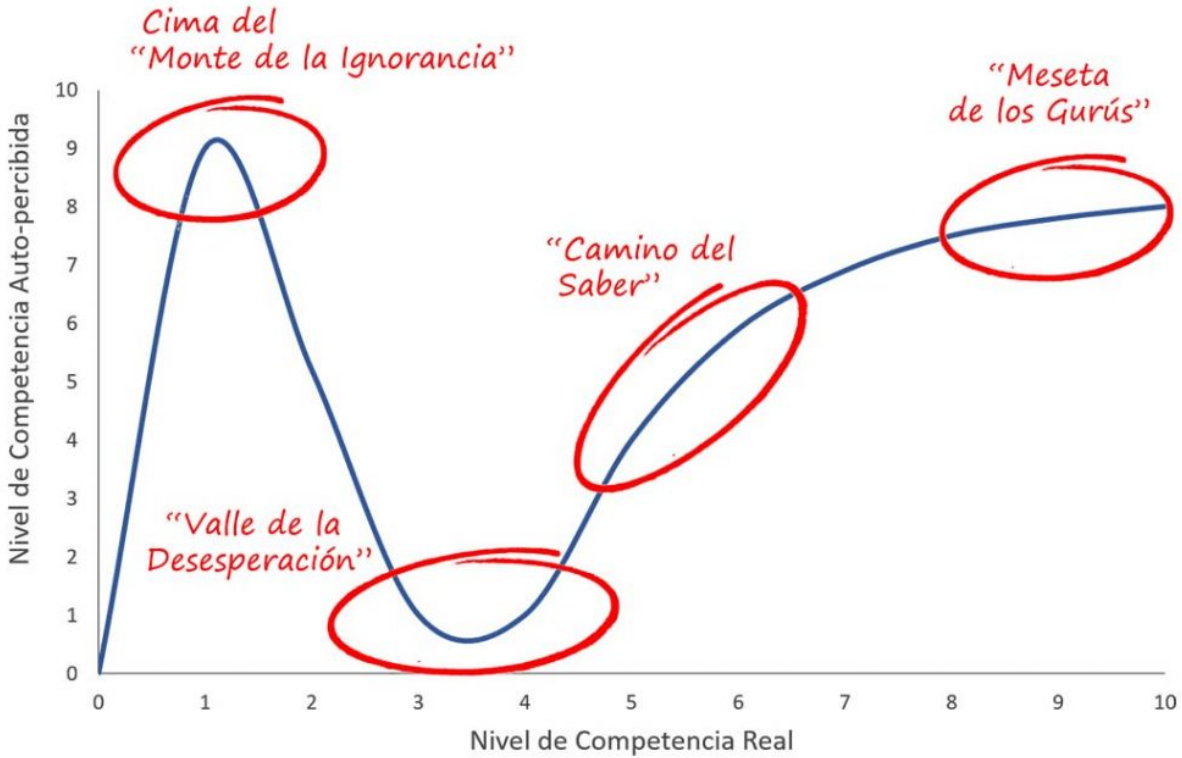




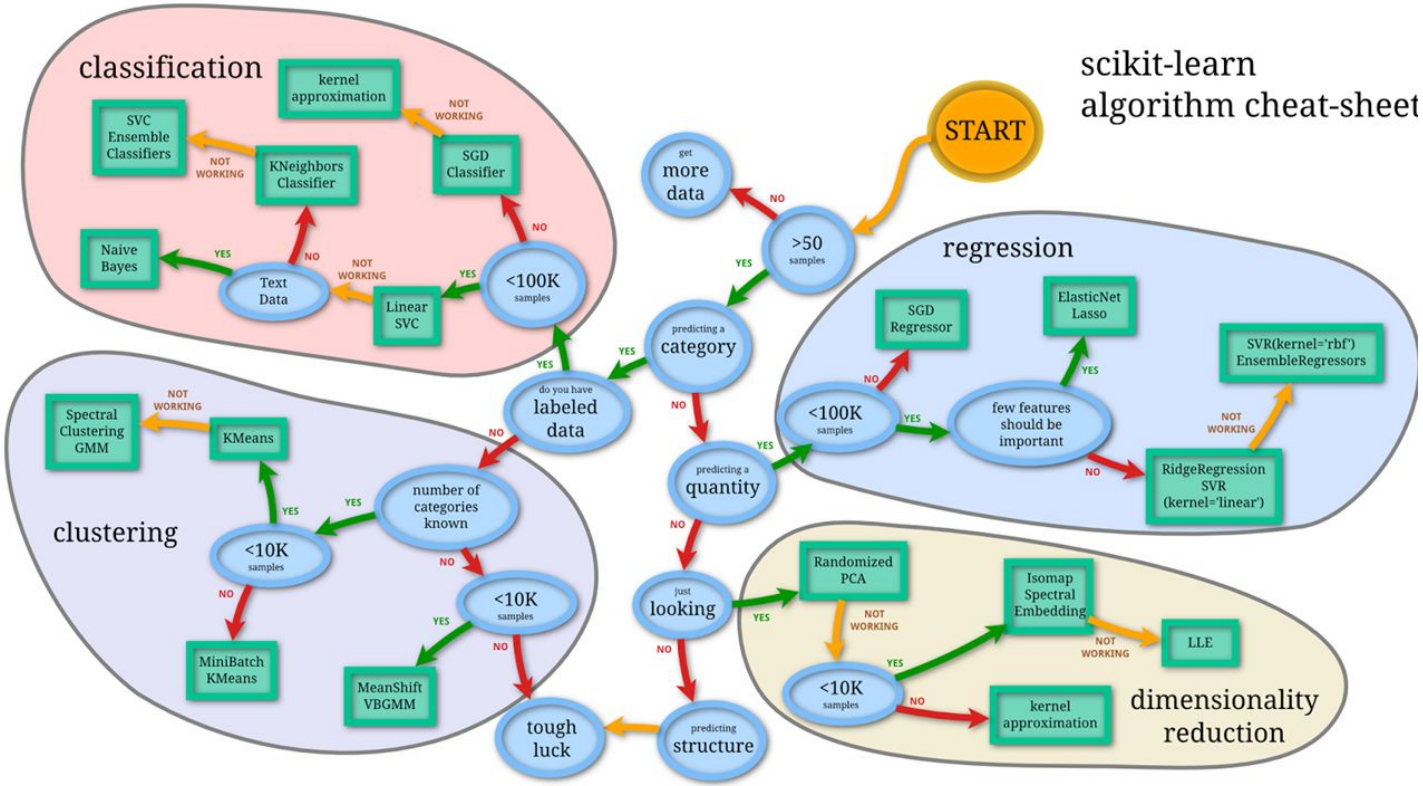
Storytelling



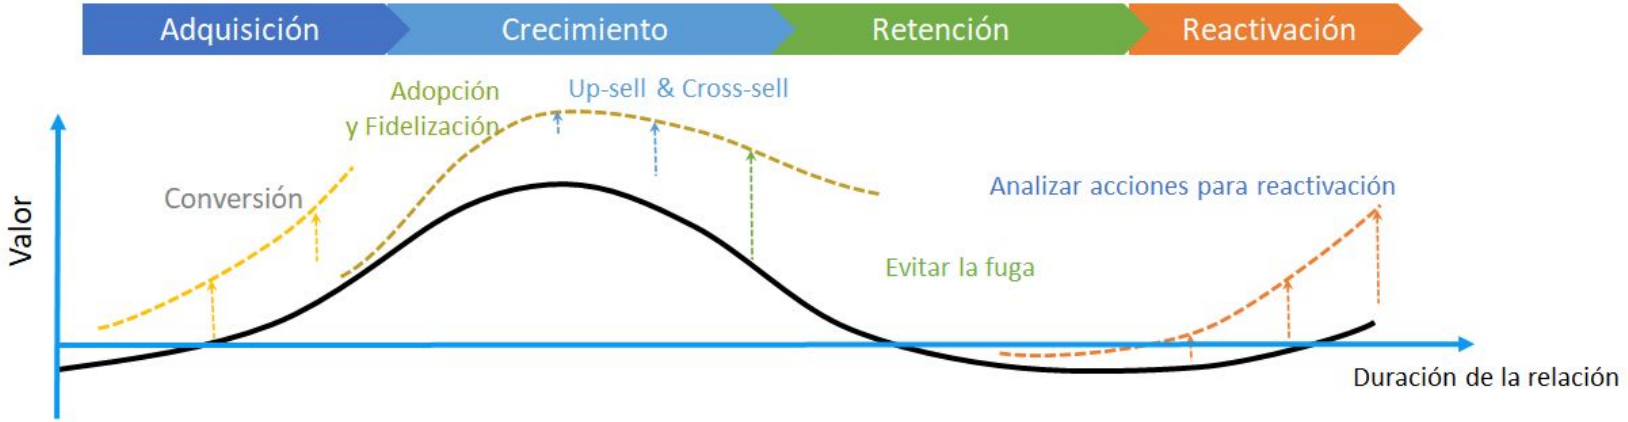
Storytelling



Hablando con el Negocio > Cómo piensa un Data Scientist



Hablando con el Negocio > Cómo piensa el negocio



Adquisición

- Look alike Models
- Audience Profile
- Real Time Offers



Crecimiento

- Segmentation (RFM)
- Cross-sell Modeling
- Up-sell Modeling
- Next Best Offer
- Recommendations
- Life time value

Retención

- **Attrition/Churn** Modeling
- Retention Offers
- Customer Value Analysis



Reactivation

- Look alike models
- Win-back offers



Primera Asignación > Abandono de clientes

Minuta de la reunión

- Nuestra empresa tiene clientes de alto valor que son los que disponen del Paquete Premium
- Un cliente de alto valor en promedio genera a la empresa 2.2m pesos al año.
- Adquirir a un cliente de alto valor es muy costoso, evitar que se vaya es más barato que conseguir uno nuevo.
- Se realizó un experimento, donde sí se gastaba 27500 pesos en un estímulo para retener a un cliente premium, el 50% acepta y se queda

Primera Asignación > Abandono de clientes

Minuta de la reunión

- Marketing quiere empezar a hacer campañas **proactivas** para evitar la fuga, **le pide a usted un listado de clientes que se estarían yendo a los cuales ellos deberían estimular.**
- Quieren la cantidad de clientes **“justa”**, les interesa **maximizar la ganancia**
- **NO** van a realizar acción alguna sobre el listado que le vayamos a dar. Van a comparar lo que enviamos con lo que paso en el real-world.

Primera Asignación > Ayuda de Michelina, Target

Dado que Michelina nos ve potencial decide ayudarnos explicandonos cómo el tiempo hace de un modelo de clasificación, un modelo predictivo.

Foto de clientes

Toda info de los clientes para un mes particular. Solo tiene datos del pasado con respecto al mes

(4 dígitos para el año + 2 dígitos para el mes

ie: 202103)

Target

Si existe un cliente en una foto N meses adelantado del mes de la Foto

CONTINUA / BAJA+1 / BAJA+2 / ... / BAJA+N

¿Qué información del futuro se puede añadir a la foto además del target?

Primera Asignación > Ayuda de Michelina, Target

202103			
id	caja_ahorro	cheques	inversiones
1	*	*	*
2	*	*	*
3	*	*	*
4	*	*	*
5	*	*	*
6	*	*	*
7	*	*	*
8	*	*	*

202104			
id	caja_ahorro	cheques	inversiones
1	*	*	*
2	*	*	*
4	*	*	*
6	*	*	*
7	*	*	*
8	*	*	*
9	*	*	*

202105			
id	caja_ahorro	cheques	inversiones
2	*	*	*
4	*	*	*
6	*	*	*
7	*	*	*
9	*	*	*
10	*	*	*

Primera Asignación > Ayuda de Michelina, Target

202103				202105
id	caja_ahorro	cheques	inversiones	clase
1	*	*	*	BAJA+2
2	*	*	*	CONT
3	*	*	*	BAJA+1
4	*	*	*	CONT
5	*	*	*	BAJA+1
6	*	*	*	CONT
7	*	*	*	CONT
8	*	*	*	BAJA+2

202104			
id	caja_ahorro	cheques	inversiones
1	*	*	*
2	*	*	*
4	*	*	*
6	*	*	*
7	*	*	*
8	*	*	*
9	*	*	*

202105			
id	caja_ahorro	cheques	inversiones
2	*	*	*
4	*	*	*
6	*	*	*
7	*	*	*
9	*	*	*
10	*	*	*

Primera Asignación > Ayuda de Michelina, Target

Nos explica por qué hay que dejar un gap de un mes, y que solo tiene sentido predecir a dos meses, dejando la construcción final del target

		TARGET				
		202103	202104	202105	202106	202107
FOTO	202103		~~BAJA+1 CONTINUA~~	BAJA+2 BAJA+1 CONTINUA	~~BAJA+3 BAJA+2 BAJA+1 CONTINUA~~	~~BAJA+4 BAJA+3 BAJA+2 BAJA+1 CONTINUA~~
	202104			~~BAJA+1 CONTINUA~~	BAJA+2 BAJA+1 CONTINUA	~~BAJA+3 BAJA+2 BAJA+1 CONTINUA~~
	202105				~~BAJA+1 CONTINUA~~	BAJA+2 BAJA+1 CONTINUA

Primera Asignación > TAREA



- El dataset que se le entrega para la primera competencia tiene la foto de 202103 a 202108, pero no tiene **target**.
- Debe armar la variable **clase_ternaria**, con las clases **CONTINUA**, **BAJA+1** y **BAJA+2**
- Puede usar R, Python, …, pero se recomienda **SQL**
- No hay una única **solución**, comporta por **zulip** al stream **#code** si la suya es diferente (lenguaje usado, código, etc) así todos aprenden a hacerlo de muchas formas distintas.

Primera Asignación > Ayuda de Michelina, Ganancia

Nos explica cómo calcular la ganancia de una virtual campaña. Razonamiento:

- Debemos entregar una lista de personas que el modelo cree que no van a irse en 2 meses.
- A todas las personas en la lista habría que estimularlas con un coste de $27.500, a priori no sabemos si se van, si se van en al mes siguiente o dentro de 2.
- Si la persona que dijimos que se iba en 2 meses, se va en el segundo mes, ganaríamos los $2.200.000 del valor del cliente. Sin embargo como la experiencia dice que solo la mitad de los estimulados se quedan, decimos que si acertamos solo ganaremos 1.100.000 pesos

Primera Asignación > Ayuda de Michelina, Ganancia

- Luego

  Ganancia = 0.5 * $2.200.000 * aciertos - $27.500 * estimulos
  Ganancia= $1.100.000 *$BAJA_2$ - $27.500 *($BAJA_2$+ $BAJA_1$+ CONTINUA)
  Ganancia= $1.072.500 *$BAJA_2$ - $27.500 *($BAJA_1$+ CONTINUA)

- Ejemplo, enviamos 3 estímulos donde hubieron 1 $BAJA_2$, 1 $BAJA_1$y 1 CONTINUA
  - El $BAJA_2$ gasta $27.500 en estímulo y ganaremos $1.100.000. Tendremos una ganancia de $1.072.500.
  - El $BAJA_1$ se nos habrá ido antes de tiempo, habremos perdido $27.500.
  - El CONTINUA no se fue del banco. Habremos estimulado erróneamente por otros $27.500.
  - La ganancia de esa campaña virtual de 3 casos nos dará $1.017.500

Primera Asignación > Ayuda de Michelina, Ganancia

Podemos representar la ecuación anterior a través de la siguiente matriz de ganancia

		Real		
		BAJA+2	BAJA+1	CONTINUA
Predicho	BAJA+2	1.072.500	–27.500	-27.500
	BAJA+1	0	0	0
	CONTINUA	0	0	0

- ¿Está bien definida la métrica de ganancia?
- ¿No debería haber un castigo cuando el modelo predice mal y decide no enviar estímulo a un registro que en realidad es un BAJA+2?

Primera Asignación > Cantidad de estímulos

Por último, ya teniendo cuál es la función de ganancias, tendremos que determinar la cantidad óptima de envíos para obtener la mayor ganancia.

Quizás algún alumnos piense en este momento:

> “¿Qué dice este? Los modelos nos devuelven la clase que corresponde, mandamos todos los que el modelo nos dice y listo.”

Bueno, NO. Un modelo devuelve un score, un valor habitualmente entre 1 y 0, que en algunos casos es la probabilidad de pertenencia de una determinada clase.

Primera Asignación > Cantidad de estímulos

Pensemos juntos:

Si un cliente tiene una prob de 0.2 de ser BAJA+2, de 0.3 de ser BAJA+1 y de 0.5 de ser CONTINUA. ¿Usted le envía un estímulo?

Defienda su posición primero con los compañeros y luego con la clase.

Primera Asignación > Probabilidad mínima

Pensemos juntos:

Con sus herramientas desarrolladas durante la primaria, secundaria, terciario, ..., determine junto a sus compañeros cúal es la probabilidad mínima frente a la cual uno debe mandar un estímulo.

Primera Asignación > Punto de corte

Dado que contamos con una función de ganancia, podemos definir cuales son todos los clientes que deben ser estimulados usando la probabilidad que devuelve el modelo.

$$f\left(x_i\right) = P\left(BAJA_2 | x_i\right) = p$$

f es el modelo que devuelve una probabilidad para el caso *x*

$$G|_{x_i} = \begin{cases} ganancia & p \\ costo & 1-p \end{cases}$$

G es una variable aleatoria (VA) que refleja la ganancia

$$E(G) = \sum_{g \in G} gP(G=g) = (ganancia)p + -(costo)(1-p)$$

$$\begin{aligned} E(G) &\geq 0 \\ -costo + (ganancia)p &\geq 0 \\ p &\geq 0.025 \end{aligned}$$

Como es una VA, tiene una esperanza matemática (E) y si es positiva, refleja que ganamos plata con ese caso. Tan solo resta buscar el valor de *p* para el que la E es mayor a 0.

Luego todo caso cuyo modelo devuelva una p mayor a 0.025 será considerado bueno.